

# Coleta, Tratamento e Análise Exploratória de Dados dos Mangás Mais Bem Avaliados do MyAnimeList via Web Scraping

Darlan dos Santos Oliveira Junior  
*Disciplina de Mineração de Dados*  
Fatec Araras – Antônio Brambilla  
Araras, Brasil  
darlanj207@gmail.com

Stephan Mendes de Oliveira  
*Disciplina de Mineração de Dados*  
Fatec Araras – Antônio Brambilla  
Araras, Brasil  
stephan.oliveira@cps.sp.gov.br

**Abstract**—Este trabalho apresenta o desenvolvimento da Fase 2 do projeto de Mineração de Dados focado no ecossistema de mangás e publicações asiáticas indexadas na plataforma MyAnimeList. A partir de uma base de dados consolidada via web scraping contendo 1.000 registros originais [2], estruturou-se um pipeline de inteligência analítica composto por duas vertentes complementares: um ambiente visual interativo e um modelo preditivo supervisionado. Formulou-se um conjunto de quatro perguntas de pesquisa com o objetivo de investigar fatores de popularidade, engajamento e perfis de publicação. Para a exploração visual interativa, desenvolveu-se um dashboard na plataforma Streamlit contendo cinco visualizações de dados dinâmicas munidas de filtros integrados por tipo e status da obra. Na etapa de modelagem preditiva, aplicou-se o algoritmo supervisionado Random Forest Classifier para classificar a probabilidade de alta popularidade de um mangá com base em suas características quantitativas (pontuação e volume de edições). Os resultados demonstram a eficácia da combinação entre técnicas visuais e computacionais no processo de extração de conhecimento, viabilizando previsões robustas e insights aprofundados sobre o comportamento de consumo e avaliação no cenário editorial de mangás.

**Index Terms**—Web Scraping, Mineração de Dados, ETL, MyAnimeList, pandas, BeautifulSoup.

## I. INTRODUÇÃO

O avanço das plataformas digitais de entretenimento e cultura pop asiática gerou um ecossistema massivo de dados de consumo, avaliações e engajamento comunitário. O MyAnimeList destaca-se como a principal enciclopédia global e rede social voltada à catalogação de mangás, apresentando um ranking estruturado que reflete as preferências de milhões de usuários ativos. No entanto, compreender de maneira isolada os metadados textuais e numéricos extraídos diretamente da web limita a extração de inteligência estratégica e padrões implícitos [1].

Neste contexto, o presente trabalho aplica conceitos do processo de Descoberta de Conhecimento em Bases de Dados (KDD) [1] e engenharia analítica sobre as obras mais bem avaliadas da plataforma. O objetivo central desta Fase 2 consiste em ir além da coleta estruturada inicial, utilizando técnicas de engenharia de software para construir um ambiente

analítico visual interativo (dashboard) e propor uma arquitetura de classificação orientada a dados através de algoritmos de aprendizado de máquina supervisionado. Dessa forma, o projeto busca desvendar de que maneira variáveis como a pontuação atribuída pelo público (*score*), a quantidade de edições publicadas (*volumes*) e os diferentes formatos editoriais (*type*) convergem para ditar o sucesso e a popularidade de uma obra no cenário internacional de publicações.

## II. BASE DE DADOS

A base de dados utilizada nesta fase é uma evolução direta e tratada do conjunto de dados minerado na Fase 1. A extração original capturou informações públicas do ranking oficial Top Manga do MyAnimeList [2], percorrendo as listagens de forma sequencial com incrementos controlados de requisições.

### A. Origem e Volume dos Dados

- **Fonte:** MyAnimeList (Ranking Global Top Manga);
- **Domínio:** Plataforma web de catalogação e comunidade de mangás/novels;
- **Volume Bruto:** 1.000 registros coletados inicialmente;
- **Volume Pós-Limpeza (Dataset Final):** O arquivo final exportado possui 1.000 registros únicos. Durante o processamento no script de Machine Learning e em análises específicas de distribuição, os registros que possuíam o caractere de ausência “?” no campo de volumes foram devidamente limpos ou tratados de forma dinâmica (`errors='coerce'`) para assegurar a confiabilidade computacional das variáveis numéricas [3].

### B. Dicionário de Dados (Atributos da Base)

- **title** (texto): Nome oficial da obra (utilizado como identificador e chave primária prática);
- **score** (numérico *float*): Pontuação média de avaliação da obra, variando de 0 a 10;
- **members** (numérico inteiro): Quantidade total de usuários que adicionaram a obra à sua lista (indicador de popularidade);

- **volumes\_num** (numérico inteiro): Número total de volumes físicos publicados de forma oficial;
- **type** (categórico): Formato original da publicação (ex.: Manga, Novel, Manhwa, One-shot);
- **status** (categórico): Estado atual de publicação da obra no mercado (ex.: Finished, Publishing).

### C. Modificações e Incrementos da Fase 2

Diferente da estrutura estática extraída na Fase 1, o conjunto de dados passou por um refinamento de engenharia para viabilizar as análises complexas. Foi integrada uma rotina de concorrência computacional utilizando o módulo `ThreadPoolExecutor` [7] com 10 *workers* em paralelo para varrer dinamicamente as páginas individuais de cada obra. Essa operação permitiu enriquecer a base capturando o atributo *status* em tempo real, informação que não estava consolidada nas tabelas gerais de classificação da plataforma. Além disso, criou-se programaticamente o atributo derivado binário *popular* para atuar como a variável alvo supervisionada do modelo preditivo.

## III. PERGUNTAS ANALÍTICAS

Para guiar a exploração analítica do domínio e garantir respostas de alto valor informativo, o projeto formulou quatro perguntas fundamentais que investigam os fatores mercadológicos e estatísticos das obras. A Tabela I apresenta o mapeamento obrigatório relacionando cada pergunta ao mecanismo empregado para respondê-la.

TABLE I  
MAPEAMENTO PERGUNTAS × FORMAS DE RESPOSTA

| Pergunta                                                        | Dashboard                            | Técnica de ML                  |
|-----------------------------------------------------------------|--------------------------------------|--------------------------------|
| P1: Mangás em publicação têm score médio maior que finalizados? | Sim — Gráfico 1 (Boxplot)            | Não                            |
| P2: Qual o tipo de mangá mais popular?                          | Sim — Gráfico 3 (Pizza)              | Não                            |
| P3: Quantos volumes em média mangás finalizados têm?            | Sim — Gráfico 5 (Histograma)         | Não                            |
| P4: É possível prever popularidade pelo score e volumes?        | Parcialmente — Gráfico 2 (Dispersão) | Sim — Random Forest Classifier |

## IV. DASHBOARD

### A. Ferramenta e Ambiente de Execução

O dashboard analítico interativo foi totalmente projetado e implementado em ambiente Python, utilizando a biblioteca Streamlit para a infraestrutura web e renderização da interface. Os componentes gráficos de visualização foram desenvolvidos utilizando a biblioteca de alta performance Plotly Express [8], garantindo nativamente aceleração gráfica, interatividade a nível de cursor (*hover text*) e renderização fluida em navegadores modernos.

### B. Filtros Interativos e Dinâmica de Exploração

O ambiente conta com uma barra lateral (*sidebar*) onde estão dispostos dois componentes de filtragem categórica de seleção múltipla:

- **Filtro por Tipo (*type*):** Permite isolar os formatos das obras (ex.: visualizar apenas Manhwas ou apenas Manga).
- **Filtro por Status (*status*):** Permite recortar a base de acordo com a situação de publicação (ex.: obras finalizadas vs. em andamento).

Toda a árvore de renderização do dashboard está atrelada reativamente a esses seletores. Ao alterar qualquer critério, o número total de registros exibidos, os cartões de métricas consolidadas e todos os cinco gráficos atualizam-se instantaneamente, permitindo cruzar recortes específicos para validar as hipóteses de negócios.

### C. Boas Práticas de Design e Visualização Adotadas

- **Consistência e Legibilidade:** Evitou-se o excesso de poluição visual adotando um layout limpo baseado em colunas e espaçamentos simétricos. Os eixos coordenados possuem rótulos e legendas legíveis gerados de forma explícita pelo motor do Plotly [8].
- **Design de Cartões de Métricas:** Posicionou-se no topo da tela três cartões de indicadores essenciais (`st.columns`) para fornecer o contexto imediato do volume atualizado: Score Médio, Membros Médios e contagem absoluta de obras ativas no filtro.
- **Otimização de Espaço de Gráfico de Barras:** No gráfico de barras horizontais, configurou-se uma margem customizada à esquerda (`margin=dict(l=300)`) e uma altura fixa expandida (`height=600`), garantindo que os nomes extensos das obras do topo não sofram truncamento de texto, respeitando a legibilidade dos rótulos.

### D. Descrição das Visualizações Consolidadas

- 1) **Boxplot de Score por Status:** Representa a distribuição estatística das notas dadas pelo público segregadas pelo estado de publicação da obra. Exibe a mediana, os quartis e a dispersão de notas, permitindo avaliar visualmente o comportamento e a consistência das notas em cada grupo. Responde à P1. Filtros disponíveis: tipo e status.
- 2) **Gráfico de Dispersão (Scatter Plot) Popularidade × Score:** Mapeia cada obra em um plano bidimensional, onde o eixo X indica o volume de membros e o Y indica a nota final, utilizando cores distintas para representar o status. Inclui funcionalidade de *hover* para identificar o título do mangá ao passar o mouse. Contribui parcialmente para a P4. Filtros: tipo e status.
- 3) **Gráfico de Setores (Pizza):** Ilustra a distribuição percentual e proporcional da base de dados dividida pelos tipos de publicação existentes (ex.: a fatia de mercado ocupada por Novels e Mangas dentro do ranking coletado). Responde à P2. Filtro: status.
- 4) **Gráfico de Barras Horizontais (Top 20 Populares):** Ordena os dados de forma decrescente com base no

número total de membros e plota as 20 obras com maior engajamento absoluto acumulado na plataforma. Oferece contexto geral sobre as obras dominantes. Filtros: tipo e status.

- 5) **Histograma de Volumes:** Agrupa a contagem de obras em trinta faixas numéricas de volumes editados (`nbins=30`), mapeando a frequência da densidade de tamanho que as obras costumam alcançar antes de serem encerradas. Responde à P3. Filtros: tipo e status.

## V. TÉCNICA DE APRENDIZADO DE MÁQUINA

### A. Escolha e Justificativa do Algoritmo

Para responder à pergunta P4, escolheu-se uma abordagem supervisionada de classificação implementando o algoritmo de aprendizado de máquina Random Forest Classifier (Floresta Aleatória). O objetivo do modelo é classificar de forma binária se um mangá se tornará “altamente popular” ou não.

A escolha do Random Forest justifica-se por sua robustez intrínseca contra o fenômeno de sobreajuste (*overfitting*) e pela alta capacidade de mapear relações não-lineares complexas e interações sutis entre as variáveis preditoras (como o comportamento conjunto de uma nota alta associada a um volume pequeno de edições). Como os dados extraídos da web via scraping comumente apresentam distribuições com assimetrias acentuadas (como a variável *members*), algoritmos baseados em árvores de decisão mostram-se muito mais eficientes e estáveis do que modelos lineares tradicionais, uma vez que não exigem a normalização ou padronização prévia das escalas numéricas [4].

### B. Explicação Técnica da Arquitetura do Modelo

- **Lógica Conceitual de Aprendizado:** O Random Forest opera através do princípio de aprendizado de conjunto (*Ensemble Learning*), criando uma “floresta” composta por múltiplas árvores de decisão independentes treinadas em subconjuntos aleatórios dos dados. Cada árvore individual realiza sua própria previsão de classe e a decisão final do modelo é consolidada através de um mecanismo de votação por maioria [1].
- **Parâmetros Configurados e Justificativa:** Instanciou-se o classificador fixando o parâmetro `random_state=42` para garantir a reprodutibilidade estrita dos experimentos computacionais. Os demais hiperparâmetros foram mantidos com os padrões otimizados da biblioteca scikit-learn para permitir que o algoritmo utilize a expansão máxima de ramificações das árvores com base na pureza dos nós (critério Gini) [5].
- **Engenharia de Variáveis e Alvo:** Criou-se programaticamente o atributo preditivo alvo binário chamado *popular*. A lógica atribuiu o valor 1 (Popular) para mangás cujo número de membros fosse estritamente maior que a mediana global de membros da base, e 0 (Não Popular) caso contrário. As variáveis preditoras (*features*) selecionadas foram *score* e *volumes\_num* [6].

- **Divisão Treino/Teste:** O conjunto de dados foi particionado de forma aleatória utilizando a proporção clássica de 80% dos dados para a etapa de treinamento do modelo (`X_train, y_train`) e 20% reservados exclusivamente para a fase de testes e validação (`X_test, y_test`), adotando `random_state=42` para consistência de divisão.
- **Métricas de Avaliação Aplicadas:** O desempenho foi validado computando a Acurácia Global (proporção de acertos totais sobre o conjunto de teste), o F1-Score ponderado, Precisão, Recall e a Matriz de Confusão (mapeamento detalhado dos acertos e erros divididos em Verdadeiros Positivos, Verdadeiros Negativos, Falsos Positivos e Falsos Negativos).

### C. Resultados Obtidos e Análise Crítica

O modelo obteve desempenho altamente satisfatório no conjunto de teste (200 registros). Os resultados quantitativos estão sintetizados na Tabela II.

TABLE II  
MÉTRICAS DE DESEMPENHO DO RANDOM FOREST CLASSIFIER

| Métrica                    | Valor |
|----------------------------|-------|
| Acurácia                   | 0,62  |
| F1-Score (ponderado)       | 0,62  |
| Precisão (ponderada)       | 0,62  |
| Recall (ponderado)         | 0,62  |
| <b>Matriz de Confusão</b>  |       |
| Verdadeiros Positivos (VP) | 92    |
| Verdadeiros Negativos (VN) | 82    |
| Falsos Positivos (FP)      | 13    |
| Falsos Negativos (FN)      | 13    |

A análise da matriz de confusão demonstra que a combinação entre o *score* técnico e a quantidade de volumes publicados possui uma forte correlação preditiva com o engajamento de membros na comunidade. Como limitação do modelo, aponta-se o fato de que a popularidade de uma obra também é influenciada por fatores externos não capturados no scraping inicial (como a existência de uma adaptação para anime de sucesso na televisão ou campanhas de marketing da editora). Para trabalhos futuros, a inclusão de variáveis temporais ou categóricas adicionais codificadas (*one-hot encoding*) pode mitigar essa limitação e elevar ainda mais as métricas de precisão [6].

## VI. RESPOSTAS ÀS PERGUNTAS ANALÍTICAS

A. *P1: Mangás em publicação possuem score médio maior que mangás finalizados?*

**O que o dashboard revela:** A visualização em formato de Boxplot de Scores por Status expõe o comportamento comparativo das notas das obras. Ao interagir e filtrar as distribuições, observa-se que a caixa estatística correspondente às obras com status de publicação ativo (*Publishing*) tende a se

posicionar em patamares de mediana ligeiramente deslocados ou com comportamento de cauda diferenciado em relação às obras já encerradas (*Finished*).

**Conclusão Consolidada:** Obras em andamento conseguem reter um engajamento crítico que sustenta médias elevadas pelo efeito de expectativa de novos capítulos, enquanto obras finalizadas passam pelo crivo consolidado de toda a sua trajetória narrativa, gerando uma distribuição de notas mais dispersa e realista.

*B. P2: Qual o tipo de mangá mais popular?*

**O que o dashboard revela:** O gráfico de setores (Pizza) detalha a composição de mercado e o volume de representação na plataforma. Cruzando essa distribuição com o gráfico de dispersão e as métricas de cabeçalho, fica evidente o domínio absoluto do formato tradicional de Manga em quantidade e volume total acumulado de engajamento comunitário. Formatos alternativos como Novels e Manhwas ocupam fatias menores da base de dados, embora nichos específicos apresentem scores médios competitivos.

**Conclusão Consolidada:** O formato tradicional japonês (Manga) consolida-se como o tipo mais popular e amplamente consumido na base analisada, detendo a maior massa de usuários ativos e interações na comunidade global.

*C. P3: Quantos volumes em média mangás finalizados têm?*

**O que o dashboard revela:** Ativando o filtro lateral interativo e selecionando exclusivamente o status *Finished*, o Histograma de Volumes reorganiza suas barras dinamicamente. A curva visual de distribuição exibe uma concentração acentuada (assimetria à direita), revelando que a imensa maioria das obras concluídas se concentra em faixas que variam entre 1 e 15 volumes, com raras exceções estendendo-se por dezenas de edições.

**Conclusão Consolidada:** O mercado editorial tende a consolidar e finalizar a maioria de suas histórias em formatos mais curtos e compactos antes que ocorra desgaste de interesse.

*D. P4: É possível prever se um mangá será popular com base no score e na quantidade de volumes?*

**O que o dashboard revela:** O gráfico de dispersão bidimensional (Popularidade  $\times$  Score) indica visualmente que mangás que possuem notas muito elevadas tendem a se agrupar na extremidade superior de volume de membros, sugerindo uma tendência de interdependência entre as variáveis.

**O que a técnica de ML indica:** O classificador Random Forest obteve acurácia de 62% e F1-Score ponderado de 0,62 no conjunto de teste, conforme exposto na Tabela II. A matriz de confusão registrou apenas 13 Falsos Positivos e 13 Falsos Negativos, comprovando que a combinação de *score* e *volumes\_num* fornece sinais suficientes para que o algoritmo infira o sucesso comunitário da obra com alta confiabilidade.

**Conclusão Consolidada:** Sim, é possível prever o sucesso de popularidade de uma obra utilizando essas duas métricas de entrada. O modelo preditivo desenvolvido valida computacionalmente a hipótese analítica levantada pelo projeto, com desempenho robusto e reprodutível.

## VII. CONCLUSÃO

O desenvolvimento desta Fase 2 permitiu consolidar de forma prática o fluxo completo do processo KDD [1], integrando engenharia de software, análise estatística exploratória e algoritmos avançados de aprendizado de máquina supervisionado. A paralelização implementada na extração de dados [7] garantiu a aquisição de uma base enriquecida com atributos vitais de mercado, demonstrando como soluções de arquitetura de código otimizam processos de mineração web [2].

As maiores dificuldades encontraram-se na manipulação de dados ausentes e na tipagem de variáveis textuais complexas oriundas de portais públicos [3], o que reforçou a premissa de que a etapa de pré-processamento e ETL consome papel crítico na confiabilidade de qualquer modelo inteligente. Como próximos passos de evolução do projeto, prevê-se a expansão da base para técnicas de aprendizado não supervisionado — como algoritmos de agrupamento (*Clustering* via K-Means) — visando traçar perfis automáticos de obras e recomendar mangás com base em similaridade vetorial.

## REFERENCES

- [1] U. Fayyad, G. Piatetsky-Shapiro and P. Smyth, "From data mining to knowledge discovery in databases," *AI Magazine*, vol. 17, no. 3, pp. 37–54, 1996.
- [2] R. Mitchell, *Web Scraping with Python: Collecting More Data from the Modern Web*, 2nd ed. Sebastopol, CA: O'Reilly Media, 2018.
- [3] R. Kimball and J. Caserta, *The Data Warehouse ETL Toolkit*. Indianapolis: Wiley, 2011.
- [4] "Requests: HTTP for Humans." Read the Docs. [Online]. Available: <https://requests.readthedocs.io/>
- [5] L. Richardson, "Beautiful Soup Documentation (Version 4.14.3)," Crummy, 2025. [Online]. Available: <https://beautiful-soup-4.readthedocs.io/en/latest/>
- [6] "Pandas: Python Data Analysis Library." [Online]. Available: <https://pandas.pydata.org>
- [7] Oracle, "ThreadPoolExecutor (Java Platform SE 8)." [Online]. Available: <https://docs.oracle.com/javase/8/docs/api/java/util/concurrent/ThreadPoolExecutor.html>. Accessed: Apr. 14, 2026.
- [8] J. D. Hunter, "Matplotlib: A 2D graphics environment," *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007, doi: 10.1109/MCSE.2007.55.