

Coleta Web Scraping

Coleta, Tratamento e Análise Exploratória de Dados dos Mangas Mais Bem Avaliados do MyAnimeList via Web Scraping

Darlan dos santos Oliveira Junior
Disciplina de Mineração de Dados
Fatec Araras - Antônio Brambilla
Araras, Brasil
darlanj207@gmail.com

Stephan Mendes de Oliveira
Disciplina de Mineração de Dados
Fatec Araras - Antônio Brambilla
Araras, Brasil
stephan.oliveira@cps.sp.gov.br

Este artigo apresenta o processo de coleta, tratamento e análise exploratória de dados dos mangás mais bem avaliados do site MyAnimeList. O trabalho foi desenvolvido no contexto da disciplina de Mineração de Dados, com o objetivo de construir uma base estruturada a partir de informações públicas do ranking de mangás da plataforma. O script foi implementado em Python utilizando as bibliotecas Requests, BeautifulSoup, pandas, expressões regulares, concorrência com ThreadPoolExecutor e matplotlib. A coleta foi configurada para percorrer até 20 páginas do ranking, em blocos de 50 itens, extraindo atributos como título, score, número de membros, quantidade de volumes, tipo e status da obra. Na etapa de ETL, os dados são organizados em DataFrame, passam por remoção de duplicatas por título, descarte de registros com ausências críticas em score e members e conversão da variável de volumes para formato numérico. Além disso, foi criada uma versão específica da base para análise da distribuição de volumes antes e depois da limpeza. Os resultados esperados demonstram a importância do pré-processamento para reduzir inconsistências e preparar a base para análises posteriores, como estudo de popularidade, comparação entre tipos de publicação e investigação da relação entre score, volumes e número de membros.

Index Terms—Web Scraping, Mineração de Dados, ETL, MyAnimeList, pandas, BeautifulSoup.

I. INTRODUÇÃO

O crescimento do volume de dados disponíveis na internet tem ampliado o uso de técnicas automatizadas de coleta e preparação de dados para fins analíticos. Entre essas técnicas, o web scraping se destaca por permitir a extração de informações diretamente do HTML de páginas web, especialmente quando não há API pública disponível para consulta estruturada. No contexto de bases culturais e de entretenimento, rankings públicos oferecem dados valiosos para estudos exploratórios, incluindo indicadores de avaliação, popularidade e características descritivas dos itens listados. O MyAnimeList é uma plataforma amplamente conhecida por disponibilizar rankings e metadados de obras japonesas e asiáticas, reunindo informações que podem ser exploradas em tarefas de

mineração de dados. Este trabalho tem como objetivo documentar a construção de uma base de dados sobre os mangás mais bem avaliados do MyAnimeList, contemplando as etapas de extração, transformação e análise exploratória inicial. O foco do projeto está na organização da base e no tratamento de inconsistências, de modo a preparar os dados para análises futuras sobre popularidade, distribuição de volumes, diferenças entre tipos de publicação e possíveis relações entre score e número de membros.

II. FUNDAMENTAÇÃO TEÓRICA

A. Processo KDD

O processo de Descoberta de Conhecimento em Bases de Dados, conhecido como KDD, é formado por um conjunto de etapas que transformam dados brutos em conhecimento útil. Em geral, esse fluxo envolve seleção, pré-processamento, transformação, mineração de dados e interpretação dos resultados. Nas etapas iniciais, o objetivo principal é garantir que a base seja consistente, compreensível e adequada para exploração posterior [1].

B. Web Scraping

Web scraping corresponde à extração automatizada de informações disponíveis em páginas web. Em vez de consumir uma interface formal de dados, o processo se baseia na leitura da estrutura HTML, utilizando seletores, classes, atributos e padrões textuais para localizar os elementos de interesse. Em projetos acadêmicos, essa abordagem é útil para construir bases próprias quando os dados estão organizados em catálogos, rankings ou listas públicas. Sua utilização, no entanto, exige cuidado com a estrutura do site, com a taxa de requisições, com o uso de identificadores de cliente apropriados e com os termos de uso da plataforma. No presente projeto, adotou-se um User-Agent explícito e uma pequena pausa entre páginas para tornar a coleta menos agressiva[2].

C. ETL e Pré-processamento

O processo de ETL envolve três movimentos principais: extração dos dados da fonte original, transformação desses dados em um formato adequado e carga em uma estrutura utilizável para consulta ou análise[3]. Em cenários de scraping, é comum encontrar dados ausentes, formatos mistos, duplicatas

e atributos coletados em diferentes níveis de granularidade. Por isso, o pré-processamento é indispensável para tornar a base analiticamente confiável.

III. METODOLOGIA

A. Definição do Problema e Fonte de Dados

A fonte de dados escolhida foi o ranking Top Manga do MyAnimeList, acessado por meio do endereço base <https://myanimelist.net/topmanga.php?limit=>. A escolha desse domínio se justifica pela disponibilidade de um ranking estruturado, pelo interesse analítico dos atributos exibidos e pelo potencial de explorar relações entre avaliação da obra, popularidade e características editoriais. O script foi configurado para percorrer offsets de 0 a 950, com incremento de 50 registros por página. Essa estratégia permite consultar até 20 páginas do ranking e, em condições ideais, extrair até 1.000 entradas brutas da listagem.

B. Perguntas de Pesquisa

1) Existe relação entre score e número de membros das obras listadas? 2) Como os diferentes tipos de publicação, como manga, manhwa e novel, se distribuem no ranking coletado? 3) A quantidade de volumes aparenta ter alguma associação com a popularidade ou com a avaliação da obra? 4) Como o status das obras, como publishing ou finished, se distribui dentro do conjunto coletado?

C. Ferramentas e Bibliotecas

- Requests: utilizada para realizar as requisições HTTP às páginas de ranking e às páginas individuais das obras[4];
- BeautifulSoup: empregada no parsing do HTML e na navegação pelos elementos de interesse[5];
- re: usada na extração de padrões textuais do bloco de informações de cada obra;
- pandas: responsável pela estrutura tabular, transformação e limpeza da base[6];
- ThreadPoolExecutor: utilizado para paralelizar a coleta do atributo status nas páginas individuais[7];
- matplotlib: empregado na geração de histogramas para comparação da distribuição de volumes antes e depois da limpeza[8];
- time: utilizado para inserir pausas curtas entre as iterações de páginas e reduzir a intensidade das requisições.

D. Processo de Web Scraping

A coleta foi desenvolvida em duas camadas. Na primeira, o script percorre as páginas do ranking e extrai diretamente os atributos visíveis em cada linha da tabela, como título, URL da obra, score e bloco textual com informações resumidas. A partir do bloco information, o código utiliza expressões regulares para identificar o tipo da obra, o número de membros e a quantidade de volumes. Quando o campo de volumes não apresenta um valor numérico claro, o script atribui o símbolo “?” como marcador de ausência. Na segunda camada, cada URL individual é enviada a uma tarefa concorrente com ThreadPoolExecutor, que acessa a página específica da obra e recupera apenas o atributo status. Essa separação reduz o tempo total de coleta, pois permite que as consultas individuais sejam processadas em paralelo com até 10 workers.

E. Pipeline ETL

- 1) Coleta dos dados a partir das páginas de ranking do MyAnimeList;
- 2) Organização inicial das informações em uma estrutura tabular com os atributos extraídos;
- 3) Consolidação das informações complementares obtidas das páginas individuais, incluindo o campo de status;
- 4) Conversão dos dados coletados para uma base estruturada para análise;
- 5) Padronização do campo referente ao número de volumes por meio de conversão para formato numérico;
- 6) Remoção de registros duplicados com base no título da obra;
- 7) Exclusão de registros com ausência de dados essenciais, especialmente nas variáveis de pontuação e quantidade de membros;
- 8) Geração de um subconjunto específico contendo apenas registros com quantidade de volumes válida, utilizado na análise da distribuição dessa variável;
- 9) Exportação da base tratada em formato CSV.

F. Pré-processamento e Limpeza

- Padronização da variável volumes por meio de conversão para formato numérico com tratamento de erros;
- Remoção de duplicatas considerando o título como identificador principal;
- Eliminação de registros com score ausente ou members ausente, considerados campos essenciais para as análises pretendidas;
- Criação de uma base contendo apenas registros com volumes válidos para fins de comparação gráfica;
- Preservação do conjunto DF para exportação em CSV, mesmo quando ainda existirem volumes não numéricos no campo original.

IV. RESULTADOS

A. Panorama da Base Bruta

Com base na lógica do script, a base bruta é formada pelos registros extraídos das páginas do ranking, acrescidos da informação de status coletada nas páginas individuais. O conjunto inicial reúne atributos numéricos, categóricos e textuais, oferecendo variedade suficiente para análises exploratórias posteriores.

Entre os campos com maior relevância analítica estão a pontuação, a quantidade de membros, o número de volumes, o tipo da obra e seu status de publicação. O atributo referente ao título funciona como chave prática para consolidação dos registros, enquanto a versão numérica da variável de volumes é criada especificamente para permitir operações quantitativas e visualizações sem a interferência do marcador textual de ausência.

B. Qualidade dos Dados

O próprio desenho do código evidencia alguns problemas típicos de bases oriundas de scraping. O primeiro deles é a

possibilidade de volumes ausentes ou ambíguos, representados inicialmente pelo símbolo “?”. O segundo é a presença potencial de títulos duplicados, o que motivou a aplicação de uma etapa de remoção de duplicidades com base no campo correspondente ao título. Além disso, registros sem pontuação ou sem número de membros são removidos por serem insuficientes para as comparações pretendidas.

C. Comparativo Antes e Depois da Limpeza

O script produz dois histogramas para comparar a distribuição do número de volumes antes e depois da limpeza. No primeiro gráfico, são considerados os valores numéricos de volumes presentes na base inicial. No segundo, a análise é repetida sobre o subconjunto final preparado para essa variável, isto é, após remoção de duplicatas, descarte de ausências críticas e filtragem de registros com volumes válidos.

Essa comparação permite observar como o tratamento influencia a forma da distribuição e reduz ruídos associados a dados ausentes ou registros repetidos. Mesmo sem executar o script neste documento, a estratégia metodológica já deixa claro que a segunda visualização tende a representar de maneira mais consistente a distribuição real dos volumes entre as obras analisadas.

D. Estrutura da Base Final

O arquivo exportado para CSV corresponde à base tratada que preserva os registros sem duplicidade e sem ausências nos campos de pontuação e quantidade de membros. Já o subconjunto utilizado para a análise de volumes reúne apenas os registros em que essa informação pôde ser convertida adequadamente para formato numérico. Essa distinção é importante porque demonstra que diferentes objetivos analíticos podem exigir recortes diferentes da mesma base tratada.

E. Interpretação dos Resultados

Os resultados esperados reforçam a importância do pré-processamento no contexto da mineração de dados. Sem a conversão da informação referente ao número de volumes, a eliminação de registros essenciais incompletos e a remoção de duplicatas, qualquer análise sobre popularidade, classificação ou distribuição tenderia a refletir ruídos da coleta, e não propriamente características do domínio estudado.

Além disso, a combinação entre atributos de avaliação, popularidade, tipo de obra e situação de publicação torna a base promissora para futuras tarefas de clusterização, análise exploratória aprofundada, construção de dashboards e investigação de padrões em obras seriadas e concluídas.

V. CONCLUSÃO

Este trabalho apresentou a construção de uma base de dados a partir do ranking Top Manga do MyAnimeList, utilizando web scraping em Python e um pipeline simples de ETL para organizar e tratar os registros coletados. O projeto demonstrou como uma listagem pública pode ser convertida em um conjunto estruturado contendo atributos relevantes

para análise exploratória. Entre os principais aprendizados do desenvolvimento destacam-se o uso combinado de scraping em páginas de listagem e páginas individuais, a utilização de concorrência para reduzir o tempo de coleta e a necessidade de tratar ausências e inconsistências antes de qualquer etapa analítica. Também ficou evidente que a exportação de uma base principal e de um subconjunto específico para análise de volumes é uma decisão metodológica útil e coerente com o problema estudado. Como próximos passos, a base produzida poderá ser explorada em atividades de correlação entre variáveis, agrupamento de perfis de obras, comparação entre tipos de publicação e visualização analítica dos dados. Dessa forma, o projeto se posiciona nas etapas de seleção, pré-processamento e transformação do fluxo de KDD, servindo como base para aplicações posteriores da disciplina.

REFERENCES

Please number citations consecutively within brackets [1]. The sentence punctuation follows the bracket [2]. Refer simply to the reference number, as in [3]—do not use “Ref. [3]” or “reference [3]” except at the beginning of a sentence: “Reference [3] was the first . . .”

Number footnotes separately in superscripts. Place the actual footnote at the bottom of the column in which it was cited. Do not put footnotes in the abstract or reference list. Use letters for table footnotes.

Unless there are six authors or more give all authors’ names; do not use “et al.”. Papers that have not been published, even if they have been submitted for publication, should be cited as “unpublished” [4]. Papers that have been accepted for publication should be cited as “in press” [5]. Capitalize only the first word in a paper title, except for proper nouns and element symbols.

For papers published in translation journals, please give the English citation first, followed by the original foreign-language citation [6].

REFERENCES

- [1] Fayyad, U., Piatetsky-Shapiro, G., Smyth, P. (1996). “From Data Mining to Knowledge Discovery in Databases”. *AI Magazine*, 17(3), 37-54.
- [2] MITCHELL, Ryan. *Web Scraping with Python: Collecting More Data from the Modern Web*. 2nd ed. Sebastopol, CA: O’Reilly Media, 2018.
- [3] KIMBALL, Ralph; CASERTA, Joe. *The Data Warehouse ETL Toolkit: Practical Techniques for Extracting, Cleaning, Conforming, and Delivering Data*. 1. ed. Indianapolis: Wiley, 2011.
- [4] “Requests: HTTP for Humans™.” Read the Docs. Disponível em: <https://requests.readthedocs.io/>
- [5] Richardson, L. (2025). *Beautiful Soup Documentation* (Version 4.14.3). Crummy. Disponível em: <https://beautiful-soup-4.readthedocs.io/en/latest/>
- [6] Pandas: Python Data Analysis Library. Disponível em: <https://pandas.pydata.org>
- [7] ORACLE. *ThreadPoolExecutor* (Java Platform SE 8). Disponível em: <https://docs.oracle.com/javase/8/docs/api/java/util/concurrent/ThreadPoolExecutor.html>. Acesso em: 14 abr. 2026.
- [8] HUNTER, John D. *Matplotlib: A 2D graphics environment*. *Computing in Science Engineering*, v. 9, n. 3, p. 90-95, 2007. DOI: 10.1109/MCSE.2007.55