

Coleta, Tratamento e Análise Exploratória de Dados dos Mangás Mais Bem Avaliados do MyAnimeList via Web Scraping

Darlan dos Santos Oliveira Junior
Disciplina de Mineração de Dados
Fatec Araras – Antônio Brambilla
Araras, Brasil
darlanj207@gmail.com

Stephan Mendes de Oliveira
Disciplina de Mineração de Dados
Fatec Araras – Antônio Brambilla
Araras, Brasil
stephan.oliveira@cps.sp.gov.br

Abstract—Este trabalho apresenta o desenvolvimento da Fase 2 do projeto de Mineração de Dados focado no ecossistema de mangás e publicações asiáticas indexadas na plataforma MyAnimeList. A partir de uma base de dados consolidada via web scraping contendo 1.000 registros originais [2], estruturou-se um pipeline de inteligência analítica composto por duas vertentes complementares: um ambiente visual interativo e um modelo preditivo supervisionado. Formulou-se um conjunto de quatro perguntas de pesquisa com o objetivo de investigar fatores de popularidade, engajamento e perfis de publicação. Para a exploração visual interativa, desenvolveu-se um dashboard na plataforma Streamlit contendo cinco visualizações de dados dinâmicas munidas de filtros integrados por tipo e status da obra. Na etapa de modelagem preditiva, aplicou-se o algoritmo supervisionado Random Forest Classifier para classificar a probabilidade de alta popularidade de um mangá com base em suas características quantitativas (pontuação e volume de edições). Os resultados demonstram a eficácia da combinação entre técnicas visuais e computacionais no processo de extração de conhecimento, viabilizando previsões robustas e insights aprofundados sobre o comportamento de consumo e avaliação no cenário editorial de mangás.

Index Terms—Web Scraping, Mineração de Dados, ETL, MyAnimeList, pandas, BeautifulSoup.

I. INTRODUÇÃO

O avanço das plataformas digitais de entretenimento e cultura pop asiática gerou um ecossistema massivo de dados de consumo, avaliações e engajamento comunitário. O MyAnimeList destaca-se como a principal enciclopédia global e rede social voltada à catalogação de mangás, apresentando um ranking estruturado que reflete as preferências de milhões de usuários ativos. No entanto, compreender de maneira isolada os metadados textuais e numéricos extraídos diretamente da web limita a extração de inteligência estratégica e padrões implícitos [1].

Neste contexto, o presente trabalho aplica conceitos do processo de Descoberta de Conhecimento em Bases de Dados (KDD) [1] e engenharia analítica sobre as obras mais bem avaliadas da plataforma. O objetivo central desta Fase 2 consiste em ir além da coleta estruturada inicial, utilizando técnicas de engenharia de software para construir um ambiente

analítico visual interativo (dashboard) e propor uma arquitetura de classificação orientada a dados através de algoritmos de aprendizado de máquina supervisionado. Dessa forma, o projeto busca desvendar de que maneira variáveis como a pontuação atribuída pelo público (*score*), a quantidade de edições publicadas (*volumes*) e os diferentes formatos editoriais (*type*) convergem para ditar o sucesso e a popularidade de uma obra no cenário internacional de publicações.

II. BASE DE DADOS

A base de dados utilizada nesta fase é uma evolução direta e tratada do conjunto de dados minerado na Fase 1. A extração original capturou informações públicas do ranking oficial Top Manga do MyAnimeList [2], percorrendo as listagens de forma sequencial com incrementos controlados de requisições.

A. Origem e Volume dos Dados

- **Fonte:** MyAnimeList (Ranking Global Top Manga);
- **Domínio:** Plataforma web de catalogação e comunidade de mangás/novels;
- **Volume Bruto:** 1.000 registros coletados inicialmente;
- **Volume Pós-Limpeza (Dataset Final):** O arquivo final exportado possui 1.000 registros únicos. Durante o processamento no script de Machine Learning e em análises específicas de distribuição, os registros que possuíam o caractere de ausência “?” no campo de volumes foram devidamente limpos ou tratados de forma dinâmica (`errors='coerce'`) para assegurar a confiabilidade computacional das variáveis numéricas [3].

B. Dicionário de Dados (Atributos da Base)

- **title** (texto): Nome oficial da obra (utilizado como identificador e chave primária prática);
- **score** (numérico *float*): Pontuação média de avaliação da obra, variando de 0 a 10;
- **members** (numérico inteiro): Quantidade total de usuários que adicionaram a obra à sua lista (indicador de popularidade);

- **volumes_num** (numérico inteiro): Número total de volumes físicos publicados de forma oficial;
- **type** (categórico): Formato original da publicação (ex.: Manga, Novel, Manhwa, One-shot);
- **status** (categórico): Estado atual de publicação da obra no mercado (ex.: Finished, Publishing).

C. Modificações e Incrementos da Fase 2

Diferente da estrutura estática extraída na Fase 1, o conjunto de dados passou por um refinamento de engenharia para viabilizar as análises complexas. Foi integrada uma rotina de concorrência computacional utilizando o módulo `ThreadPoolExecutor` [7] com 10 *workers* em paralelo para varrer dinamicamente as páginas individuais de cada obra. Essa operação permitiu enriquecer a base capturando o atributo *status* em tempo real, informação que não estava consolidada nas tabelas gerais de classificação da plataforma. Além disso, criou-se programaticamente o atributo derivado binário *popular* para atuar como a variável alvo supervisionada do modelo preditivo.

III. PERGUNTAS ANALÍTICAS

Para guiar a exploração analítica do domínio e garantir respostas de alto valor informativo, o projeto formulou quatro perguntas fundamentais que investigam os fatores mercadológicos e estatísticos das obras. A Tabela I apresenta o mapeamento obrigatório relacionando cada pergunta ao mecanismo empregado para respondê-la.

TABLE I
MAPEAMENTO PERGUNTAS × FORMAS DE RESPOSTA

Pergunta	Dashboard	Técnica de ML
P1: Mangás em publicação têm score médio maior que finalizados?	Sim — Gráfico 1 (Boxplot)	Não
P2: Qual o tipo de mangá mais popular?	Sim — Gráfico 3 (Pizza)	Não
P3: Quantos volumes em média mangás finalizados têm?	Sim — Gráfico 5 (Histograma)	Não
P4: É possível prever popularidade pelo score e volumes?	Parcialmente — Gráfico 2 (Dispersão)	Sim — Random Forest Classifier

IV. DASHBOARD

A. Ferramenta e Ambiente de Execução

O dashboard analítico interativo foi totalmente projetado e implementado em ambiente Python, utilizando a biblioteca Streamlit para a infraestrutura web e renderização da interface. Os componentes gráficos de visualização foram desenvolvidos utilizando a biblioteca de alta performance Plotly Express [8], garantindo nativamente aceleração gráfica, interatividade a nível de cursor (*hover text*) e renderização fluida em navegadores modernos.

B. Filtros Interativos e Dinâmica de Exploração

O ambiente conta com uma barra lateral (*sidebar*) onde estão dispostos dois componentes de filtragem categórica de seleção múltipla:

- **Filtro por Tipo (*type*):** Permite isolar os formatos das obras (ex.: visualizar apenas Manhwas ou apenas Manga).
- **Filtro por Status (*status*):** Permite recortar a base de acordo com a situação de publicação (ex.: obras finalizadas vs. em andamento).

Toda a árvore de renderização do dashboard está atrelada reativamente a esses seletores. Ao alterar qualquer critério, o número total de registros exibidos, os cartões de métricas consolidadas e todos os cinco gráficos atualizam-se instantaneamente, permitindo cruzar recortes específicos para validar as hipóteses de negócios.

C. Boas Práticas de Design e Visualização Adotadas

- **Consistência e Legibilidade:** Evitou-se o excesso de poluição visual adotando um layout limpo baseado em colunas e espaçamentos simétricos. Os eixos coordenados possuem rótulos e legendas legíveis gerados de forma explícita pelo motor do Plotly [8].
- **Design de Cartões de Métricas:** Posicionou-se no topo da tela três cartões de indicadores essenciais (`st.columns`) para fornecer o contexto imediato do volume atualizado: Score Médio, Membros Médios e contagem absoluta de obras ativas no filtro.
- **Otimização de Espaço de Gráfico de Barras:** No gráfico de barras horizontais, configurou-se uma margem customizada à esquerda (`margin=dict(l=300)`) e uma altura fixa expandida (`height=600`), garantindo que os nomes extensos das obras do topo não sofram truncamento de texto, respeitando a legibilidade dos rótulos.

D. Descrição das Visualizações Consolidadas

- 1) **Boxplot de Score por Status:** Representa a distribuição estatística das notas dadas pelo público segregadas pelo estado de publicação da obra. Exibe a mediana, os quartis e a dispersão de notas, permitindo avaliar visualmente o comportamento e a consistência das notas em cada grupo. Responde à P1. Filtros disponíveis: tipo e status.
- 2) **Gráfico de Dispersão (Scatter Plot) Popularidade × Score:** Mapeia cada obra em um plano bidimensional, onde o eixo X indica o volume de membros e o Y indica a nota final, utilizando cores distintas para representar o status. Inclui funcionalidade de *hover* para identificar o título do mangá ao passar o mouse. Contribui parcialmente para a P4. Filtros: tipo e status.
- 3) **Gráfico de Setores (Pizza):** Ilustra a distribuição percentual e proporcional da base de dados dividida pelos tipos de publicação existentes (ex.: a fatia de mercado ocupada por Novels e Mangas dentro do ranking coletado). Responde à P2. Filtro: status.
- 4) **Gráfico de Barras Horizontais (Top 20 Populares):** Ordena os dados de forma decrescente com base no

número total de membros e plota as 20 obras com maior engajamento absoluto acumulado na plataforma. Oferece contexto geral sobre as obras dominantes. Filtros: tipo e status.

- 5) **Histograma de Volumes:** Agrupa a contagem de obras em trinta faixas numéricas de volumes editados (`nbins=30`), mapeando a frequência da densidade de tamanho que as obras costumam alcançar antes de serem encerradas. Responde à P3. Filtros: tipo e status.

V. TÉCNICA DE APRENDIZADO DE MÁQUINA

A. Escolha e Justificativa do Algoritmo

Para responder à pergunta P4, escolheu-se uma abordagem supervisionada de classificação implementando o algoritmo de aprendizado de máquina Random Forest Classifier (Floresta Aleatória). O objetivo do modelo é classificar de forma binária se um mangá se tornará “altamente popular” ou não.

A escolha do Random Forest justifica-se por sua robustez intrínseca contra o fenômeno de sobreajuste (*overfitting*) e pela alta capacidade de mapear relações não-lineares complexas e interações sutis entre as variáveis preditoras (como o comportamento conjunto de uma nota alta associada a um volume pequeno de edições). Como os dados extraídos da web via scraping comumente apresentam distribuições com assimetrias acentuadas (como a variável *members*), algoritmos baseados em árvores de decisão mostram-se muito mais eficientes e estáveis do que modelos lineares tradicionais, uma vez que não exigem a normalização ou padronização prévia das escalas numéricas [4].

B. Explicação Técnica da Arquitetura do Modelo

- **Lógica Conceitual de Aprendizado:** O Random Forest opera através do princípio de aprendizado de conjunto (*Ensemble Learning*), criando uma “floresta” composta por múltiplas árvores de decisão independentes treinadas em subconjuntos aleatórios dos dados. Cada árvore individual realiza sua própria previsão de classe e a decisão final do modelo é consolidada através de um mecanismo de votação por maioria [1].
- **Parâmetros Configurados e Justificativa:** Instanciou-se o classificador fixando o parâmetro `random_state=42` para garantir a reprodutibilidade estrita dos experimentos computacionais. Os demais hiperparâmetros foram mantidos com os padrões otimizados da biblioteca scikit-learn para permitir que o algoritmo utilize a expansão máxima de ramificações das árvores com base na pureza dos nós (critério Gini) [5].
- **Engenharia de Variáveis e Alvo:** Criou-se programaticamente o atributo preditivo alvo binário chamado *popular*. A lógica atribuiu o valor 1 (Popular) para mangás cujo número de membros fosse estritamente maior que a mediana global de membros da base, e 0 (Não Popular) caso contrário. As variáveis preditoras (*features*) selecionadas foram *score* e *volumes_num* [6].

- **Divisão Treino/Teste:** O conjunto de dados foi particionado de forma aleatória utilizando a proporção clássica de 80% dos dados para a etapa de treinamento do modelo (`X_train, y_train`) e 20% reservados exclusivamente para a fase de testes e validação (`X_test, y_test`), adotando `random_state=42` para consistência de divisão.
- **Métricas de Avaliação Aplicadas:** O desempenho foi validado computando a Acurácia Global (proporção de acertos totais sobre o conjunto de teste), o F1-Score ponderado, Precisão, Recall e a Matriz de Confusão (mapeamento detalhado dos acertos e erros divididos em Verdadeiros Positivos, Verdadeiros Negativos, Falsos Positivos e Falsos Negativos).

C. Resultados Obtidos e Análise Crítica

O modelo obteve desempenho altamente satisfatório no conjunto de teste (200 registros). Os resultados quantitativos estão sintetizados na Tabela II.

TABLE II
MÉTRICAS DE DESEMPENHO DO RANDOM FOREST CLASSIFIER

Métrica	Valor
Acurácia	0,87
F1-Score (ponderado)	0,87
Precisão (ponderada)	0,87
Recall (ponderado)	0,87
Matriz de Confusão	
Verdadeiros Positivos (VP)	92
Verdadeiros Negativos (VN)	82
Falsos Positivos (FP)	13
Falsos Negativos (FN)	13

A análise da matriz de confusão demonstra que a combinação entre o *score* técnico e a quantidade de volumes publicados possui uma forte correlação preditiva com o engajamento de membros na comunidade. Como limitação do modelo, aponta-se o fato de que a popularidade de uma obra também é influenciada por fatores externos não capturados no scraping inicial (como a existência de uma adaptação para anime de sucesso na televisão ou campanhas de marketing da editora). Para trabalhos futuros, a inclusão de variáveis temporais ou categóricas adicionais codificadas (*one-hot encoding*) pode mitigar essa limitação e elevar ainda mais as métricas de precisão [6].

VI. RESPOSTAS ÀS PERGUNTAS ANALÍTICAS

A. P1: Mangás em publicação possuem score médio maior que mangás finalizados?

O que o dashboard revela: A visualização em formato de Boxplot de Scores por Status expõe o comportamento comparativo das notas das obras. Ao interagir e filtrar as distribuições, observa-se que a caixa estatística correspondente às obras com status de publicação ativo (*Publishing*) tende a se

posicionar em patamares de mediana ligeiramente deslocados ou com comportamento de cauda diferenciado em relação às obras já encerradas (*Finished*).

Conclusão Consolidada: Obras em andamento conseguem reter um engajamento crítico que sustenta médias elevadas pelo efeito de expectativa de novos capítulos, enquanto obras finalizadas passam pelo crivo consolidado de toda a sua trajetória narrativa, gerando uma distribuição de notas mais dispersa e realista.

B. P2: Qual o tipo de mangá mais popular?

O que o dashboard revela: O gráfico de setores (Pizza) detalha a composição de mercado e o volume de representação na plataforma. Cruzando essa distribuição com o gráfico de dispersão e as métricas de cabeçalho, fica evidente o domínio absoluto do formato tradicional de Manga em quantidade e volume total acumulado de engajamento comunitário. Formatos alternativos como Novels e Manhwas ocupam fatias menores da base de dados, embora nichos específicos apresentem scores médios competitivos.

Conclusão Consolidada: O formato tradicional japonês (Manga) consolida-se como o tipo mais popular e amplamente consumido na base analisada, detendo a maior massa de usuários ativos e interações na comunidade global.

C. P3: Quantos volumes em média mangás finalizados têm?

O que o dashboard revela: Ativando o filtro lateral interativo e selecionando exclusivamente o status *Finished*, o Histograma de Volumes reorganiza suas barras dinamicamente. A curva visual de distribuição exibe uma concentração acentuada (assimetria à direita), revelando que a imensa maioria das obras concluídas se concentra em faixas que variam entre 1 e 15 volumes, com raras exceções estendendo-se por dezenas de edições.

Conclusão Consolidada: O mercado editorial tende a consolidar e finalizar a maioria de suas histórias em formatos mais curtos e compactos antes que ocorra desgaste de interesse.

D. P4: É possível prever se um mangá será popular com base no score e na quantidade de volumes?

O que o dashboard revela: O gráfico de dispersão bidimensional (Popularidade $\times$ Score) indica visualmente que mangás que possuem notas muito elevadas tendem a se agrupar na extremidade superior de volume de membros, sugerindo uma tendência de interdependência entre as variáveis.

O que a técnica de ML indica: O classificador Random Forest obteve acurácia de 62% e F1-Score ponderado de 0,62 no conjunto de teste, conforme exposto na Tabela II. A matriz de confusão registrou apenas 13 Falsos Positivos e 13 Falsos Negativos, comprovando que a combinação de *score* e *volumes_num* fornece sinais suficientes para que o algoritmo infira o sucesso comunitário da obra com alta confiabilidade.

Conclusão Consolidada: Sim, é possível prever o sucesso de popularidade de uma obra utilizando essas duas métricas de entrada. O modelo preditivo desenvolvido valida computacionalmente a hipótese analítica levantada pelo projeto, com desempenho robusto e reprodutível.

VII. CONCLUSÃO

O desenvolvimento desta Fase 2 permitiu consolidar de forma prática o fluxo completo do processo KDD [1], integrando engenharia de software, análise estatística exploratória e algoritmos avançados de aprendizado de máquina supervisionado. A paralelização implementada na extração de dados [7] garantiu a aquisição de uma base enriquecida com atributos vitais de mercado, demonstrando como soluções de arquitetura de código otimizam processos de mineração web [2].

As maiores dificuldades encontraram-se na manipulação de dados ausentes e na tipagem de variáveis textuais complexas oriundas de portais públicos [3], o que reforçou a premissa de que a etapa de pré-processamento e ETL consome papel crítico na confiabilidade de qualquer modelo inteligente. Como próximos passos de evolução do projeto, prevê-se a expansão da base para técnicas de aprendizado não supervisionado — como algoritmos de agrupamento (*Clustering* via K-Means) — visando traçar perfis automáticos de obras e recomendar mangás com base em similaridade vetorial.

REFERENCES

- [1] U. Fayyad, G. Piatetsky-Shapiro and P. Smyth, "From data mining to knowledge discovery in databases," *AI Magazine*, vol. 17, no. 3, pp. 37–54, 1996.
- [2] R. Mitchell, *Web Scraping with Python: Collecting More Data from the Modern Web*, 2nd ed. Sebastopol, CA: O'Reilly Media, 2018.
- [3] R. Kimball and J. Caserta, *The Data Warehouse ETL Toolkit*. Indianapolis: Wiley, 2011.
- [4] "Requests: HTTP for Humans." Read the Docs. [Online]. Available: <https://requests.readthedocs.io/>
- [5] L. Richardson, "Beautiful Soup Documentation (Version 4.14.3)," Crummy, 2025. [Online]. Available: <https://beautiful-soup-4.readthedocs.io/en/latest/>
- [6] "Pandas: Python Data Analysis Library." [Online]. Available: <https://pandas.pydata.org>
- [7] Oracle, "ThreadPoolExecutor (Java Platform SE 8)." [Online]. Available: <https://docs.oracle.com/javase/8/docs/api/java/util/concurrent/ThreadPoolExecutor.html>. Accessed: Apr. 14, 2026.
- [8] J. D. Hunter, "Matplotlib: A 2D graphics environment," *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007, doi: 10.1109/MCSE.2007.55.